

LOCAL AI SDK.

Tether QVAC

Автономный запуск локальных языковых моделей, Whisper STT, синтеза речи, OCR и RAG на пользовательском устройстве без обращения к сторонним облачным серверам.

qv.ac // local-first

TABLE OF CONTENTS

• 01. ПРОБЛЕМА ОБЛАЧНЫХ API

• 02. КОНЦЕПЦИЯ TETHER QVAC

• 03. C++ ЯДРО & TURBOQUANT

• 04. УСТАНОВКА И QVAC CLI

• 05. OPENAI-СОВМЕСТИМЫЙ ШЛЮЗ

• 06. МУЛЬТИМОДАЛЬНЫЙ КОНВЕЙЕР

• 07. LOCAL RAG БЕЗ УТЕЧЕК

• 08. ПРАКТИЧЕСКИЙ ДЕМО-СТЕНД

// PLATFORM SUMMARY

100%

Автономная работа нейросетей
на личном оборудовании без
аренды чужих мощностей.

APACHE-2.0 LICENSE

CLOUD CRISIS

Традиционный подход с отправкой запросов в облачные API (OpenAI, Google) больше не устраивает бизнес по трем фундаментальным причинам:

УТЕЧКИ ДАННЫХ (NDA)

Передача закрытых файлов компании, финансовой отчетности и персональных данных пользователей нарушает GDPR и корпоративные соглашения.

ЭКСПОНЕНТА ЗАТРАТ

Посекундная плата за каждый миллион токенов делает масштабирование сервисов экономически невыгодным при росте базы клиентов.

// RISK ANALYSIS

OFFLINE: 0%

При обрыве интернет-канала или сбоях зарубежного провайдера все агенты полностью заблокированы.

РЕШЕНИЕ: ON-DEVICE INFERENCE

// STABLE INTELLIGENCE

TETHER ECOSYSTEM

- C++ Runtime (Metal / CUDA)
- P2P Holepunch Swarm
- Node.js & Python SDK
- Zero Cloud Architecture

SOVEREIGN AI ENGINE

STABLE, NOT RENTED

Sovereign AI

Компания Tether разработала платформу QVAC с целью дать каждому человеку и бизнесу собственный суверенный движок искусственного интеллекта, который принадлежит владельцу, а не арендуется у облачных корпораций.

ЛИЦЕНЗИЯ

Apache-2.0

100% Открытый исходный код

РАСПРОСТРАНЕНИЕ

P2P Swarm

Раздача весов через Holepunch

ЗАВИСИМОСТЬ

0% Cloud

Полная изоляция от сети

PERFORMANCE

Аппаратная оптимизация для работы моделей на потребительских компьютерах и смартфонах:

-70% RAM

Алгоритм квантования и сжатия памяти TurboQuant

Снижает объем KV-кэша контекста, позволяя запускать большие модели на устройствах с 4–8 GB RAM.

30+ TOK/S

Прямое аппаратное ускорение на чипах Metal / CUDA

Нативное C++ ядро без посредников взаимодействует с графическими и нейронными ядрами процессора.

1.2 GB

Минимальный порог памяти для квантованных моделей

Модели размера 1B–3B параметров (Llama 3.2 1B Q4_0) плавно работают на мобильных устройствах.

MULTIMODAL

QVAC объединяет все модальности восприятия в едином SDK без сторонних платных сервисов:

Whisper STT

qvac-fabric-speech

Локальное распознавание речи на C++ `whisper.cpp`.
Задержка < 150 мс.

Speech TTS

Piper Voice Engine

Синтез естественной речи без отправки текста в сеть.
0 расходов на озвучку.

ONNX OCR

@qvac/ocr-onnx

Оптическое считывание символов TrOCR. Оцифровка сканов и счетов в памяти.

Offline NMT

Neural Machine Translation

Машинный перевод текстов между десятками языков полностью автономно.

□ Все мультимодальные модули работают через общие C++ интерфейсы SDK.

OPENAI GATEWAY

Локальный сервер на 100% повторяет спецификацию OpenAI API. Замена облака происходит без переписывания клиентского кода — меняется лишь адрес шлюза.

ЭНДПОИНТЫ

- `/v1/chat/completions` (SSE Stream)
- `/v1/models`
- `/v1/embeddings`

СОВМЕСТИМОСТЬ

- LangChain & LlamaIndex
- OpenCode, Cline & Cursor
- Vercel AI SDK & VS Code Continue

// 1 LINE INTEGRATION

baseUrl: `"http://localhost:11434/v1"`

Любые существующие агентские пайплайны и плагины редакторов начинают обращаться к локальному C++ движку без облачных счетов.

STATUS: HTTP 200 OK (PORT 11434)

LOCAL RAG

0 BYTES TO CLOUD

Пакет @qvac/rag позволяет работать с конфиденциальными базами знаний. Векторизация и поиск происходят строго в оперативной памяти компьютера.

01. Чанкинг документов

Разбиение локальных файлов (.pdf, .txt, .md) на смысловые фрагменты прямо на диске пользователя.

02. Локальные эмбединги

Вычисление векторных представлений моделью эмбедингов на NPU/CPU без обращения к внешним API.

03. Косинусный поиск в RAM

Мгновенное сканирование In-Memory VectorStore и генерация ответа локальной LLM с точными ссылками.

DEMO STAND

Практическая часть, подготовленная и протестированная для допуска к проекту:

ИНФЕРЕНС LLM

quickstart.js

Запуск квантованной модели со стримингом токенов через tokenStream и выгрузкой из памяти.

Node.js / @qvac/sdk

ЛОКАЛЬНЫЙ RAG

rag_demo.js

Индексация локальных NDA-документов в VectorStore и контекстный ответ без сети.

VectorStore in RAM

OPENAI СЕРВЕР

mock_server.py

Автономный сервер на порту 11434 на Python для надежного живого показа перед комиссией.

OpenAI Protocol

THANK YOU.

for Attention

Все требования к допуску выполнены в полном объеме: инструменты освоены, прототипы протестированы, стенд готов к живой демонстрации. Благодарю за внимание и готов ответить на вопросы!

qvac.tether.io